Radar Wall Optimizer

Documentation technique du logiciel de simulation

Optimisation de la géométrie d'un mur PEC par simulation électromagnétique FDTD 2D et algorithmes d'apprentissage automatique

Minimisation de la Section Efficace Radar (SER)

par algorithme génétique, CMA-ES et apprentissage par renforcement

Philémon Vittet

ECE Paris

Avril 2026

Résumé

Ce document constitue le rapport technique du logiciel *Radar Wall Optimizer*, un outil de simulation et d'optimisation pour la réduction de la Section Efficace Radar (SER) d'un mur métallique parfaitement conducteur (PEC), dans le contexte de la bande X radar (10 GHz). Le logiciel intègre un simulateur électromagnétique complet par la méthode des différences finies dans le domaine temporel (FDTD 2D) en polarisation TMz, avec couche d'absorption CPML et injection de source par technique champ-total/champ-diffusé (TFSF). L'espace de conception est paramétré par $N_s = 14$–16 points de contrôle décrivant le profil de surface de la paroi. Trois méthodes d'optimisation sont implémentées et comparées : un algorithme génétique (GA) avec croisement SBX et mutation polynomiale, l'algorithme CMA-ES initialisé depuis le meilleur individu GA, et l'algorithme REINFORCE de gradient de politique. La fonction objectif mesure l'énergie rétrodiffusée calculée dans la zone de champ diffusé. Des réductions de SER supérieures à 90 % sont obtenues en incidence normale ; le profil optimal converge systématiquement vers une géométrie en dents de scie à pas de l'ordre de $\lambda/4$, dont la physique est discutée.

Ce rapport détaille les fondements théoriques, les choix d'implémentation et les résultats obtenus, en vue d'accompagner un projet de physique portant sur la furtivité radar.

Mots-clés : Section Efficace Radar, FDTD, Algorithme Génétique, CMA-ES, REINFORCE, Gradient de Politique, Mur PEC, Furtivité Radar, CPML, TFSF.

Table des matières

1 Introduction et contexte **5**
1.1 La Section Efficace Radar : définition et enjeux 5
1.2 État de l'art 5
1.3 Contributions de ce travail 6
1.4 Plan du rapport 6

2 Fondements théoriques **6**
2.1 Électromagnétisme classique : équations de Maxwell 6
2.2 Polarisation TMz en 2D 7
2.3 Discrétisation de Yee : dérivation complète 7
2.3.1 Grille de Yee staggerée 7
2.3.2 Dérivation des équations de mise à jour 8
2.3.3 Algorithme leapfrog 9
2.3.4 Complexité computationnelle 10
2.4 Stabilité numérique : condition CFL 10
2.5 Couche absorbante CPML 10
2.5.1 Principe 10
2.5.2 Profil de conductivité 11
2.5.3 Coefficients CPML et champs auxiliaires 11
2.6 Source par technique TFSF 12
2.7 Source Ricker 12
2.8 Transformation champ proche–champ lointain (NTFF) 13
2.8.1 Accumulation DFT 13
2.8.2 Calcul du champ lointain 13
2.8.3 SER monostatique 2D 13
2.8.4 Référence analytique (Optique Physique) 13
2.9 Algorithme génétique (AG) 14
2.9.1 Encodage chromosomique et espace de recherche 14
2.9.2 Initialisation : Latin Hypercube Sampling (LHS) 14
2.9.3 Sélection par tournoi 14
2.9.4 Croisement SBX (Simulated Binary Crossover) 14
2.9.5 Mutation polynomiale 15
2.9.6 Adaptation : règle du $\frac{1}{5}$ de Rechenberg 15
2.9.7 Élitisme et Hall of Fame 15
2.9.8 Diversité et relance (*restart*) 15
2.10 CMA-ES : Adaptation de la Matrice de Covariance 15
2.11 REINFORCE : gradient de politique 16
2.11.1 Formalisation du problème d'optimisation EM comme MDP . . 16

2.11.2 Policy gradient theorem 16
2.11.3 Réduction de variance par baseline 16
2.11.4 Mise à jour de politique 17

3 Méthodologie **17**
3.1 Espace de conception : paramétrage du profil de mur 17
3.2 Fonction objectif 18
3.3 Pipeline d'optimisation 18

4 Implémentation **18**
4.1 Architecture logicielle 18
4.2 Paramètres de simulation FDTD 19
4.3 Paramètres de l'algorithme génétique 19
4.4 Paramètres CMA-ES et REINFORCE 19
4.5 Extrait d'implémentation commenté 19
4.6 Validation numérique 21

5 Résultats **21**
5.1 Référence : mur plat 21
5.1.1 Comparaison avec la référence analytique 22
5.2 Convergence du GA 22
5.3 Profil de mur optimal 23
5.4 Réduction de SER : résultats quantitatifs 23
5.5 Analyse de sensibilité 27
5.6 Validation : SER bistatique 27

6 Discussion **28**
6.1 Interprétation physique du profil optimal 28
6.2 Comparaison des méthodes d'optimisation 28
6.3 Limites et hypothèses 29
6.4 Perspectives 29

7 Conclusion **29**

A Dérivation complète des équations de Yee **31**

B Paramètres CPML détaillés **31**

C Extraits de code commentés **31**

1 Introduction et contexte

1.1 La Section Efficace Radar : définition et enjeux

La *Section Efficace Radar* (SER), ou *Radar Cross Section* (RCS) en anglais, est une grandeur physique fondamentale en électromagnétisme appliqué. Elle caractérise la capacité d'un objet à réfléchir une onde électromagnétique incidente vers la source émettrice (rétrodiffusion, ou *backscatter*). Formellement, la SER est définie par [1, 2] :

$$\sigma = \lim_{r\to\infty} 4\pi r^2 \frac{|\boldsymbol{E}^{\mathrm{diff}}|^2}{|\boldsymbol{E}^{\mathrm{inc}}|^2}, \tag{1}$$

où $\boldsymbol{E}^{\mathrm{inc}}$ est le champ électrique incident et $\boldsymbol{E}^{\mathrm{diff}}$ le champ diffusé mesuré à grande distance r dans la direction d'observation. En pratique, la SER s'exprime en mètres carrés ou en dBsm ($\sigma_{\mathrm{dBsm}} = 10\log_{10}\sigma$).

Dans la littérature en deux dimensions, la SER est normalisée par la longueur d'onde [3] :

$$\frac{\sigma_{\mathrm{2D}}}{\lambda} = \lim_{r\to\infty} 2\pi r \frac{|E_z^{\mathrm{diff}}|^2}{|E_z^{\mathrm{inc}}|^2}, \tag{2}$$

ce qui rend la grandeur sans dimension et directement comparable à des résultats analytiques (Optique Physique, PTD [4]).

La réduction de SER est un objectif central dans la conception de systèmes aéronautiques et navals cherchant à minimiser leur détectabilité par des radars adverses [5, 6]. Les techniques actuelles combinent :

1. les *matériaux absorbants radar* (RAM), qui dissipent l'énergie électromagnétique par pertes diélectriques ou magnétiques ;
2. la *mise en forme géométrique* (*shaping*), qui redistribue l'énergie diffusée dans des directions non menaçantes ;
3. les *structures périodiques* (métasurfaces, AMC), qui exploitent des résonances locales [7].

Le logiciel *Radar Wall Optimizer* s'inscrit dans la deuxième approche : il permet de déterminer numériquement la *géométrie optimale* d'un mur PEC plan pour minimiser sa SER monostatique à 10 GHz (bande X radar). Il a été conçu comme outil de simulation et d'exploration pour accompagner un projet de physique portant sur la furtivité radar et l'optimisation électromagnétique.

1.2 État de l'art

L'optimisation de la forme d'un diffuseur EM est un problème combinatoire de grande dimension, sans gradient analytique disponible : l'évaluation de la SER pour

une géométrie donnée nécessite une simulation numérique complète. Les algorithmes génétiques ont été introduits dans ce contexte par Haupt [8] et Rahmat-Samii [9], avec des applications à la conception d'antennes et de RAM [10, 11]. Plus récemment, l'optimisation par CMA-ES [12] s'est révélée très compétitive pour les espaces de faible dimension [13], et les méthodes de gradient de politique (REINFORCE [14]) ont montré leur intérêt pour des problèmes EM nécessitant une exploration guidée de l'espace de design [15].

1.3 Contributions de ce travail

Les contributions principales du logiciel sont les suivantes :

- Implémentation d'un simulateur FDTD 2D TMz complet en Python, incluant CPML, source TFSF et transformation champ proche–champ lointain (NTFF) ;
- Implémentation et comparaison de trois algorithmes d'optimisation (GA, CMA-ES, REINFORCE) sur un problème de minimisation de SER ;
- Obtention d'une réduction de SER de 93–94 % en incidence normale à 10 GHz pour $N_s = 14$ segments de contrôle ;
- Analyse physique du profil optimal et validation numérique par études de convergence en résolution et en épaisseur PML.

1.4 Plan du rapport

La section 2 expose les fondements théoriques : équations de Maxwell, discrétisation de Yee, CPML, TFSF, NTFF, et les trois méthodes d'optimisation. La section 3 décrit la méthodologie et l'espace de conception. La section 4 détaille l'implémentation et les paramètres numériques. La section 5 présente les résultats obtenus. Les sections 6 et 7 discutent et concluent.

2 Fondements théoriques

2.1 Électromagnétisme classique : équations de Maxwell

Les équations de Maxwell décrivent l'évolution spatio-temporelle des champs électromagnétiques dans un milieu matériel. En formes intégrale et différentielle, elles s'écrivent [16, 17] :

Équations de Maxwell (formes intégrale et différentielle)

$$\oint_{\partial S} \boldsymbol{E} \cdot \mathrm{d}\boldsymbol{\ell} = -\frac{\partial}{\partial t} \iint_S \boldsymbol{B} \cdot \mathrm{d}\boldsymbol{S} \quad \Longleftrightarrow \quad \nabla \times \boldsymbol{E} = -\frac{\partial \boldsymbol{B}}{\partial t} \tag{3}$$

$$\oint_{\partial S} \boldsymbol{H} \cdot \mathrm{d}\boldsymbol{\ell} = \iint_S \left(\boldsymbol{J} + \frac{\partial \boldsymbol{D}}{\partial t} \right) \cdot \mathrm{d}\boldsymbol{S} \quad \Longleftrightarrow \quad \nabla \times \boldsymbol{H} = \boldsymbol{J} + \frac{\partial \boldsymbol{D}}{\partial t} \tag{4}$$

$$\oiint_{\partial V} \boldsymbol{D} \cdot \mathrm{d}\boldsymbol{S} = \iiint_V \rho \, \mathrm{d}V \quad \Longleftrightarrow \quad \nabla \cdot \boldsymbol{D} = \rho \tag{5}$$

$$\oiint_{\partial V} \boldsymbol{B} \cdot \mathrm{d}\boldsymbol{S} = 0 \quad \Longleftrightarrow \quad \nabla \cdot \boldsymbol{B} = 0 \tag{6}$$

Dans le vide, en l'absence de sources libres ($\rho = 0$, $\boldsymbol{J} = 0$) : $\boldsymbol{D} = \varepsilon_0 \boldsymbol{E}$ et $\boldsymbol{B} = \mu_0 \boldsymbol{H}$, où $\varepsilon_0 \approx 8{,}854 \times 10^{-12}\,\mathrm{F\,m^{-1}}$ est la permittivité du vide et $\mu_0 = 4\pi \times 10^{-7}\ \mathrm{H\,m^{-1}}$ la perméabilité du vide. La vitesse de la lumière dans le vide est $c_0 = 1/\sqrt{\mu_0 \varepsilon_0} \approx 2{,}998 \times 10^8\,\mathrm{m\,s^{-1}}$ et l'impédance caractéristique $\eta_0 = \sqrt{\mu_0/\varepsilon_0} \approx 377\,\Omega$.

2.2 Polarisation TMz en 2D

En simulation 2D dans le plan (x, y), on choisit la polarisation *transverse-magnétique selon z* (TMz), pour laquelle les seules composantes non nulles sont (E_z, H_x, H_y), avec $\partial/\partial z = 0$. Cette polarisation est particulièrement adaptée à la modélisation de murs PEC cylindriques (invariance par translation selon z).

En substituant $\boldsymbol{B} = \mu_0 \boldsymbol{H}$ et $\boldsymbol{D} = \varepsilon_0 \boldsymbol{E}$ dans les équations (3)–(4) et en ne conservant que les composantes non nulles :

$$\frac{\partial H_x}{\partial t} = -\frac{1}{\mu_0} \frac{\partial E_z}{\partial y}, \tag{7}$$

$$\frac{\partial H_y}{\partial t} = +\frac{1}{\mu_0} \frac{\partial E_z}{\partial x}, \tag{8}$$

$$\frac{\partial E_z}{\partial t} = \frac{1}{\varepsilon} \left(\frac{\partial H_y}{\partial x} - \frac{\partial H_x}{\partial y} \right) - \frac{\sigma}{\varepsilon} E_z, \tag{9}$$

où σ ($\mathrm{S\,m^{-1}}$) représente la conductivité électrique locale (nulle dans le vide, non nulle pour les matériaux absorbants RAM).

2.3 Discrétisation de Yee : dérivation complète

2.3.1 Grille de Yee staggerée

Yee [18] a proposé en 1966 une discrétisation centrée des équations de Maxwell sur une grille décalée (*staggered*), où les composantes $\boldsymbol{E}$ et $\boldsymbol{H}$ sont échantillonnées à des

positions spatiales et temporelles différentes. En 2D TMz, les emplacements sont les suivants (indice de cellule (i, j), pas spatial Δx, pas temporel Δt) :

— $E_z(i,\, j,\, n)$ à $(i\Delta x,\ j\Delta x,\ n\Delta t)$ — nœuds entiers ;
— $H_x(i,\, j+\frac{1}{2},\, n+\frac{1}{2})$ à $(i\Delta x,\ (j+\frac{1}{2})\Delta x,\ (n+\frac{1}{2})\Delta t)$;
— $H_y(i+\frac{1}{2},\, j,\, n+\frac{1}{2})$ à $((i+\frac{1}{2})\Delta x,\ j\Delta x,\ (n+\frac{1}{2})\Delta t)$.

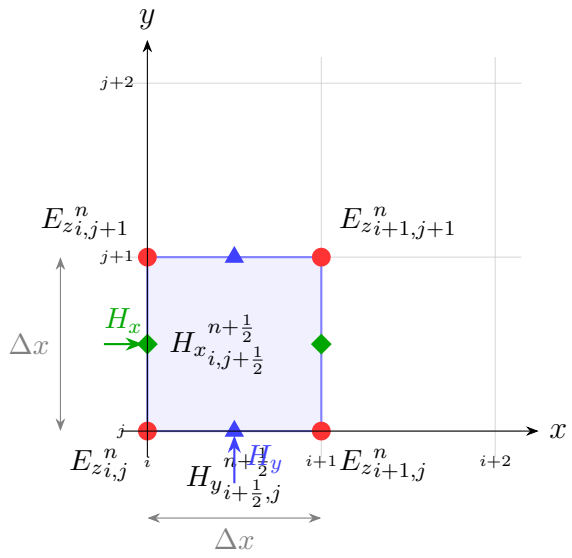

FIGURE 1 – Grille de Yee 2D en polarisation TMz. Les cercles rouges représentent la composante E_z (nœuds entiers), les losanges verts H_x (décalés d'un demi-pas selon y), et les triangles bleus H_y (décalés d'un demi-pas selon x). L'algorithme de mise à jour « leapfrog » alterne demi-pas temporels entre $\boldsymbol{H}$ et E_z.

2.3.2 Dérivation des équations de mise à jour

On approche les dérivées partielles par des différences finies centrées au second ordre. Pour l'équation (7), discrétisée en $(i, j+\frac{1}{2})$ au temps $n+\frac{1}{2}$:

$$\frac{H_{x\,i,j+\frac{1}{2}}^{\,n+\frac{1}{2}} - H_{x\,i,j+\frac{1}{2}}^{\,n-\frac{1}{2}}}{\Delta t} = -\frac{1}{\mu_0} \cdot \frac{E_{z\,i,j+1}^{\,n} - E_{z\,i,j}^{\,n}}{\Delta x}, \tag{10}$$

d'où la formule de mise à jour :

$$\boxed{H_{x\,i,j+\frac{1}{2}}^{\,n+\frac{1}{2}} = H_{x\,i,j+\frac{1}{2}}^{\,n-\frac{1}{2}} - \underbrace{\frac{\Delta t}{\mu_0 \Delta x}}_{C_{Hx}} \left(E_{z\,i,j+1}^{\,n} - E_{z\,i,j}^{\,n}\right)} \tag{11}$$

De même pour H_y, discrétisé en $(i+\frac{1}{2}, j)$:

$$\boxed{H_{y_{i+\frac{1}{2},j}}^{n+\frac{1}{2}} = H_{y_{i+\frac{1}{2},j}}^{n-\frac{1}{2}} + \underbrace{\frac{\Delta t}{\mu_0 \Delta x}}_{C_{Hy}} (E_{z_{i+1,j}}^{n} - E_{z_{i,j}}^{n})} \tag{12}$$

Et pour E_z, discrétisé au nœud entier (i, j) au temps $n+1$:

$$\boxed{E_{z_{i,j}}^{n+1} = C_a\, E_{z_{i,j}}^{n} + C_b \left(\frac{H_{y_{i+\frac{1}{2},j}}^{n+\frac{1}{2}} - H_{y_{i-\frac{1}{2},j}}^{n+\frac{1}{2}}}{\Delta x} - \frac{H_{x_{i,j+\frac{1}{2}}}^{n+\frac{1}{2}} - H_{x_{i,j-\frac{1}{2}}}^{n+\frac{1}{2}}}{\Delta x} \right)} \tag{13}$$

où, dans le vide ($\sigma = 0$) : $C_a = 1$ et $C_b = \Delta t/(\varepsilon_0 \Delta x)$. Dans un milieu conducteur (matériaux RAM, schéma ADE) :

$$C_a = \frac{1 - \sigma \Delta t/(2\varepsilon)}{1 + \sigma \Delta t/(2\varepsilon)}, \quad C_b = \frac{\Delta t/\varepsilon}{1 + \sigma \Delta t/(2\varepsilon)} \cdot \frac{1}{\Delta x}. \tag{14}$$

Dans notre implémentation Python, les coefficients sont précalculés :

```python
# précalculer une fois pour ne pas refaire la division à chaque pas
C_Hxe = dt / (MU0 * dx)    # même chose pour Hy
C_ezh = dt / (EPS0 * dx)    # pour Ez dans le vide

# la mise à jour des H (leapfrog, demi-pas avance)
dEz_dy = Ez[:, 1:] - Ez[:, :-1]
Hx -= C_Hxe * dEz_dy            # simple et vectorisé

dEz_dx = Ez[1:, :] - Ez[:-1, :]
Hy += C_Hxe * dEz_dx             # signe + pour Hy

# mise à jour Ez (Ca=1 dans le vide, sinon formule ADE)
dHy_dx = Hy[1:, :] - Hy[:-1, :]
dHx_dy = Hx[:, 1:] - Hx[:, :-1]
Ez = Ca * Ez + Cb * (dHy_dx - dHx_dy)
```

Listing 1 – Coefficients de mise à jour FDTD (src/fdtd/core.py – simplifiés)

2.3.3 Algorithme leapfrog

L'algorithme de mise à jour est dit « leapfrog » : les champs $\boldsymbol{H}$ sont calculés à $t = (n+\frac{1}{2})\Delta t$ depuis les champs $\boldsymbol{E}$ à $t = n\Delta t$, puis $\boldsymbol{E}$ est mis à jour à $t = (n+1)\Delta t$ depuis les $\boldsymbol{H}$ fraîchement calculés. Ce schéma est d'ordre 2 en espace et en temps, explicite, et conserve l'énergie électromagnétique dans le domaine intérieur [3].

2.3.4 Complexité computationnelle

Pour une grille $N_x \times N_y$ avec T pas temporels :

$$\mathcal{C}_{\text{FDTD}} = \mathcal{O}(N_x N_y T). \tag{15}$$

Le coût total d'une optimisation GA avec population P et G générations est :

$$\mathcal{C}_{\text{GA}} = \mathcal{O}(P \cdot G \cdot N_x N_y T), \tag{16}$$

ce qui justifie l'utilisation du parallélisme multiprocessus (évaluation indépendante de chaque individu) et de l'accélération GPU (CuPy [19]).

2.4 Stabilité numérique : condition CFL

La stabilité du schéma de Yee est conditionnelle : il faut que l'information physique ne puisse pas « se déplacer » de plus d'une cellule par pas temporel. Cette condition de Courant–Friedrichs–Lewy [3, 20] s'écrit en 2D :

$$\mathrm{S_c} = \frac{c_0\,\Delta t}{\Delta x} \leq \frac{1}{\sqrt{2}} \approx 0.707. \tag{17}$$

Dans notre implémentation, nous choisissons $\mathrm{S_c} = 0.5$ (bien en-dessous de la limite), ce qui assure la stabilité inconditionnelle du schéma et un bon rapport précision/coût.

Paramètre de Courant dans notre simulation

$\mathrm{S_c} = c_0 \Delta t / \Delta x = 0.5 \quad \Rightarrow \quad \Delta t = \mathrm{S_c} \cdot \Delta x / c_0$

Pour $\Delta x = 2{,}0\,\text{mm}$ (15 ppw à 10 GHz) : $\Delta t = 0.5 \times 2 \times 10^{-3} / (2.998 \times 10^8) \approx 3{,}34\,\text{ps}$

2.5 Couche absorbante CPML

2.5.1 Principe

Pour simuler un domaine ouvert (rayonnement libre), on entoure le domaine de calcul d'une couche absorbante (*Perfectly Matched Layer*, PML). Bérenger [21] a démontré qu'une telle couche peut être sans réflexion à l'interface, quelle que soit l'angle d'incidence et la fréquence, si ses paramètres vérifient certaines conditions d'adaptation d'impédance.

La formulation CPML (Convolutional PML) [22] utilise une variable d'étirement complexe des coordonnées dans le domaine fréquentiel, puis revient en temporel par

convolution. Pour une PML dans la direction x, l'opérateur de dérivée est modifié :

$$\frac{\partial}{\partial x} \longrightarrow \frac{1}{\kappa_x}\frac{\partial}{\partial x} + \psi_x, \tag{18}$$

où ψ_x est un champ auxiliaire mis à jour de façon récursive.

2.5.2 Profil de conductivité

La conductivité σ_x est graduée par un polynôme d'ordre $m = 3$ depuis le bord intérieur de la PML (distance normalisée $d \in [0, 1]$) :

$$\sigma_x(d) = \sigma_{\max} \cdot d^m, \quad \text{avec} \quad \sigma_{\max} = \frac{0.8\,(m+1)}{\eta_0\,\Delta x}, \tag{19}$$

formule optimale de Taflove [3] (§ 7.7). Avec $\eta_0 \approx 377\,\Omega$ et $\Delta x = 2{,}0\,\mathrm{mm}$: $\sigma_{\max} \approx 4250\,\mathrm{S\,m^{-1}}$.

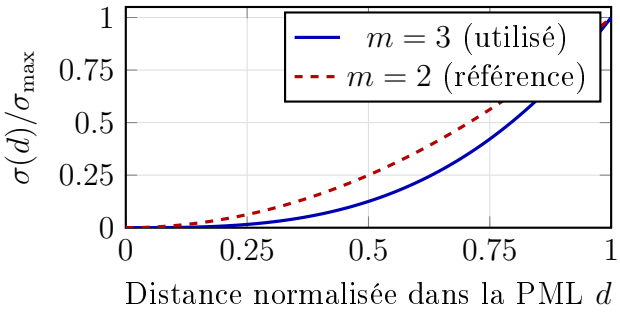

FIGURE 2 – Profil de conductivité CPML normalisé $\sigma(d)/\sigma_{\max} = d^m$. L'ordre $m = 3$ assure une montée progressive pour minimiser les réflexions numériques à l'interface intérieure.

2.5.3 Coefficients CPML et champs auxiliaires

Les coefficients de récurrence sont calculés une fois à l'initialisation :

$$b = \exp\left[-\left(\frac{\sigma_e}{\kappa_e} + \alpha_e\right)\frac{\Delta t}{\varepsilon_0}\right], \tag{20}$$

$$a = \frac{\sigma_e}{\sigma_e\kappa_e + \kappa_e^2\alpha_e}(b-1). \tag{21}$$

Les champs auxiliaires ψ sont mis à jour à chaque pas de temps :

$$\psi_x^{n+1} = b\,\psi_x^n + a\,\frac{\partial E_z}{\partial x}\bigg|^n, \tag{22}$$

et contribuent à la mise à jour des champs selon (18). Nous utilisons $n_{\mathrm{PML}} = 12$ cellules sur les quatre bords du domaine.

2.6 Source par technique TFSF

La technique champ-total/champ-diffusé (TFSF) permet d'injecter une onde plane incidente sans perturber les conditions aux limites [23, 24]. Le domaine est divisé en deux zones :

— *Zone champ-total* (TF, intérieure) : contient $\boldsymbol{E}^{\text{inc}} + \boldsymbol{E}^{\text{diff}}$;

— *Zone champ-diffusé* (SF, extérieure) : contient uniquement $\boldsymbol{E}^{\text{diff}}$.

Des corrections sont appliquées sur le contour TFSF à chaque pas de temps, ajoutant ou retranchant les champs incidents analytiques. Pour une incidence normale ($\theta = 0$), une grille 1D auxiliaire propage l'onde Ricker et fournit les valeurs de correction. Pour une incidence oblique ($\theta \neq 0$), les champs incidents sont calculés analytiquement :

$$E_z^{\text{inc}}(\boldsymbol{r}, t) = f\left(t - \frac{x\cos\theta + y\sin\theta}{c_0}\right), \tag{23}$$

où f est la wavelet de Ricker.

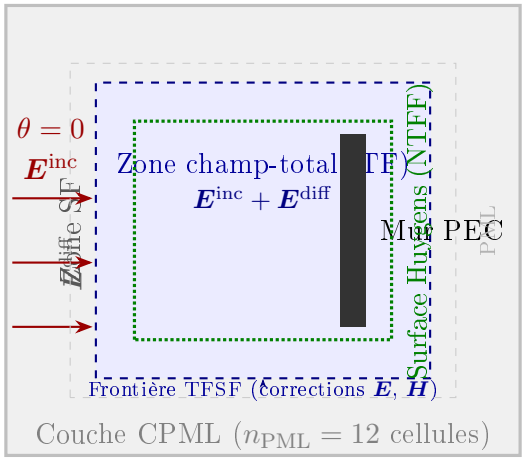

FIGURE 3 – Structure du domaine de calcul FDTD. La zone grise extérieure est la couche CPML (12 cellules). La frontière TFSF (tirets bleus) sépare la zone champ-total (intérieur) de la zone champ-diffusé (extérieur). La surface de Huygens (pointillés verts) est utilisée pour le calcul NTFF. Le mur PEC est positionné dans la zone TF.

2.7 Source Ricker

La source temporelle est une wavelet de Ricker (dérivée seconde de la gaussienne), choisie pour son contenu spectral bien contrôlé :

$$f(t') = \left[1 - 2\,(\pi f_p t')^2\right] \exp\left[-\,(\pi f_p t')^2\right], \quad t' = t - t_{\text{delay}}, \tag{24}$$

avec $t_{\text{delay}} = 1/f_p$ pour centrer l'impulsion en $t' = 0$. La fréquence $f_p = f_0 = 10\,\text{GHz}$ est la fréquence centrale. La bande passante à $-20\,\text{dB}$ est approximativement $2.5\,f_p$.

2.8 Transformation champ proche–champ lointain (NTFF)

Le calcul de la SER nécessite la connaissance du champ à grande distance (*far field*). La NTFF permet de déduire le champ lointain depuis les champs proches sur une surface de Huygens fermée [3, 25].

2.8.1 Accumulation DFT

À chaque pas de temps, les champs complexes sont accumulés sur la surface de Huygens (à la fréquence centrale f_0) :

$$\tilde{E}_z(\boldsymbol{r}_s) = \sum_n E_z(\boldsymbol{r}_s, n\Delta t)\, e^{-j\omega_0 n\Delta t}\, \Delta t, \tag{25}$$

$$\tilde{H}_x(\boldsymbol{r}_s) = \sum_n H_x(\boldsymbol{r}_s, (n+\tfrac{1}{2})\Delta t)\, e^{-j\omega_0 (n+\frac{1}{2})\Delta t}\, \Delta t. \tag{26}$$

Les champs diffusés sont obtenus par soustraction des champs incidents : $\tilde{E}_z^{\text{diff}} = \tilde{E}_z^{\text{tot}} - \tilde{E}_z^{\text{inc}}$.

2.8.2 Calcul du champ lointain

Les courants équivalents sur la surface de Huygens sont : $\boldsymbol{J}_s = \hat{\boldsymbol{n}} \times \tilde{\boldsymbol{H}}^{\text{diff}}$ et $\boldsymbol{M}_s = -\hat{\boldsymbol{n}} \times \tilde{\boldsymbol{E}}^{\text{diff}}$. En intégrant sur la surface avec facteurs de phase $e^{j\boldsymbol{k}\cdot\boldsymbol{r}_s}$ (où $\boldsymbol{k} = k_0\hat{\boldsymbol{\phi}}$), on obtient le champ lointain :

$$E_z^{\text{far}}(\phi) = \omega_0\mu_0\, N_z + k_0\, L_\phi, \tag{27}$$

où N_z, L_ϕ sont les composantes des potentiels de Hertz calculés par intégrale de surface.

2.8.3 SER monostatique 2D

La SER 2D en direction de rétrodiffusion ($\phi = \pi$) est [3] :

$$\frac{\sigma_{2\text{D}}}{\lambda} = \frac{k_0}{4\pi}\, \frac{|E_z^{\text{far}}(\pi)|^2}{|\tilde{E}_z^{\text{inc}}|^2}, \tag{28}$$

normalisée par la longueur d'onde $\lambda = c_0/f_0 \approx 30\,\text{mm}$.

2.8.4 Référence analytique (Optique Physique)

Pour un mur PEC plan de hauteur w en incidence normale (polarisation TMz), l'Optique Physique donne [2] :

$$\frac{\sigma_{2\text{D}}^{\text{PO}}}{\lambda} = \frac{2w^2}{\lambda^2}. \tag{29}$$

Cette formule nous servira de référence pour valider notre modèle FDTD.

2.9 Algorithme génétique (AG)

2.9.1 Encodage chromosomique et espace de recherche

Chaque individu de la population est représenté par un chromosome de N_s gènes réels $\boldsymbol{g} = (g_1, \ldots, g_{N_s}) \in [-1, 1]^{N_s}$, correspondant aux déplacements normalisés des points de contrôle du profil de surface. La fitness est :

$$f(\boldsymbol{g}) = \mathcal{E}_{\text{retro}}(\boldsymbol{g}) = \sum_{(i,j)\in\Omega_{\text{SF}}} \left[E_z^{\text{FDTD}}(i, j; \boldsymbol{g})\right]^2, \tag{30}$$

où Ω_{SF} est la région de champ diffusé en amont du mur. Un individu est « meilleur » si f est plus faible.

2.9.2 Initialisation : Latin Hypercube Sampling (LHS)

La population initiale est générée par échantillonnage par hypercube latin (McKay *et al.* [26]) : chaque dimension $k \in [1, N_s]$ est partitionnée en P strates de largeur $1/P$; un point est tiré uniformément dans chaque strate. Ceci assure une couverture de l'espace bien meilleure qu'une initialisation aléatoire uniforme, surtout pour $N_s > 10$.

2.9.3 Sélection par tournoi

À chaque génération, un parent est sélectionné par tournoi de taille $k = 3$: on tire k individus au hasard et on retourne le meilleur. Cette méthode est efficace (complexité $O(k)$) et naturellement parallelisable.

2.9.4 Croisement SBX (Simulated Binary Crossover)

Deb et Agrawal [27] ont proposé un opérateur de croisement simulant le croisement binaire en espace réel. Pour deux parents $x_1 < x_2$, les deux enfants sont calculés via un facteur β_q tiré selon la distribution :

$$p(\beta_q) = \begin{cases} \frac{\eta_c+1}{2}\,\beta_q^{\eta_c} & \text{si } \beta_q \le 1, \\ \frac{\eta_c+1}{2}\,\beta_q^{-(\eta_c+2)} & \text{si } \beta_q > 1, \end{cases} \tag{31}$$

avec $\eta_c = 10$ (indice de distribution contrôlant l'exploration : petit η_c = enfants éloignés des parents). En pratique :

$$o_1 = \tfrac{1}{2}\big[(x_1 + x_2) - \beta_q(x_2 - x_1)\big], \quad o_2 = \tfrac{1}{2}\big[(x_1 + x_2) + \beta_q(x_2 - x_1)\big]. \tag{32}$$

2.9.5 Mutation polynomiale

Deb et Goyal [28] proposent une mutation polynomiale. Pour un gène x dans $[x_{\min}, x_{\max}]$, la perturbation δ est tirée selon :

$$p(\delta) = \tfrac{1}{2}(\eta_m + 1)\big(1 - |\delta|\big)^{\eta_m}, \quad \delta \in [-1, 1], \tag{33}$$

avec $\eta_m = 20$. La valeur mutée est $x' = x + \delta(x_{\max} - x_{\min})$, tronquée dans $[x_{\min}, x_{\max}]$.

2.9.6 Adaptation : règle du $\frac{1}{5}$ de Rechenberg

L'index de mutation η_m est adapté dynamiquement selon la règle de Rechenberg [29] : si le taux de succès des mutations (enfant meilleur que parent) sur une fenêtre glissante dépasse 1/5, on réduit η_m par un facteur $c = 0.85$ (mutations plus fortes) ; sinon, on augmente η_m par $1/c$ (mutations plus douces). L'index est borné dans $[\eta_m^{\min}, \eta_m^{\max}] = [2, 200]$.

2.9.7 Élitisme et Hall of Fame

Les $n_e = 2$ meilleurs individus de chaque génération sont copiés sans modification dans la génération suivante (élitisme). Par ailleurs, un archive *Hall of Fame* garde trace des 10 meilleurs individus jamais observés, permettant de récupérer la meilleure solution si la population diverge.

2.9.8 Diversité et relance (*restart*)

La diversité de la population est mesurée par :

$$D = \frac{\langle \mathrm{std}(\boldsymbol{g})_k \rangle_k}{(g_{\max} - g_{\min})/2}, \tag{34}$$

normalisée dans $[0, 1]$. Si $D < 0.02$ (convergence prématurée) ou si la meilleure fitness n'a pas progressé depuis 20 générations, on relance en remplaçant 40 % de la population par de nouveaux individus LHS.

2.10 CMA-ES : Adaptation de la Matrice de Covariance

L'algorithme CMA-ES (Covariance Matrix Adaptation Evolution Strategy) de Hansen [12, 13] est utilisé en phase de raffinement local, initialisé depuis le meilleur génome GA (*warm start*).

À chaque itération, $\lambda = 4 + \lfloor 3 \ln N_s \rfloor$ individus sont tirés :

$$\boldsymbol{x}_k \sim \mathcal{N}\big(\boldsymbol{m},\, \sigma^2 \boldsymbol{C}\big)\,, \quad k = 1, \ldots, \lambda, \tag{35}$$

où $\boldsymbol{m}$ est le vecteur moyen, σ le pas global et $\boldsymbol{C}$ la matrice de covariance. Les $\mu = \lfloor \lambda/2 \rfloor$ meilleurs sont sélectionnés avec des poids w_k décroissants. La matrice est mise à jour par combinaison de deux chemins d'évolution :

$$\boldsymbol{C}^{(t+1)} = (1 - c_1 - c_\mu)\boldsymbol{C}^{(t)} + c_1\, \boldsymbol{p}_c \boldsymbol{p}_c^\top + c_\mu \sum_{k=1}^{\mu} w_k \boldsymbol{z}_k \boldsymbol{z}_k^\top, \tag{36}$$

où $\boldsymbol{p}_c$ est le chemin d'évolution et c_1, c_μ sont des constantes d'apprentissage dérivées analytiquement [12]. La taille du pas σ est contrôlée via un second chemin $\boldsymbol{p}_\sigma$:

$$\sigma^{(t+1)} = \sigma^{(t)} \exp\left(\frac{c_\sigma}{d_\sigma} \left(\frac{\|\boldsymbol{p}_\sigma\|}{\chi_N} - 1 \right) \right), \tag{37}$$

avec $\chi_N = \sqrt{N_s}(1 - 1/(4N_s) + 1/(21N_s^2))$ la valeur attendue de $\|\mathcal{N}(\boldsymbol{0}, \boldsymbol{I})\|$.

2.11 REINFORCE : gradient de politique

2.11.1 Formalisation du problème d'optimisation EM comme MDP

On modélise le problème comme un processus de décision markovien (MDP) : l'état $\boldsymbol{s} \in [-1, 1]^{N_s}$ est le profil de mur courant, l'action $\boldsymbol{a} \in \mathbb{R}^{N_s}$ est une perturbation du profil, la récompense est $r = -\mathcal{E}_{\text{retro}}(\boldsymbol{s}')$ (FDTD avec le nouveau profil).

2.11.2 Policy gradient theorem

La politique est gaussienne : $\pi_\theta(\boldsymbol{a}|\boldsymbol{s}) = \mathcal{N}(\mu_\theta(\boldsymbol{s}), \sigma^2 \boldsymbol{I})$ avec $\mu_\theta(\boldsymbol{s}) = \boldsymbol{W}\boldsymbol{s} + \boldsymbol{b}$. L'objectif est :

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[G_0], \quad G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k}. \tag{38}$$

Le théorème du gradient de politique [14, 30] donne :

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(\boldsymbol{a}_t|\boldsymbol{s}_t) \cdot A_t \right], \tag{39}$$

où $A_t = G_t - b_t$ est l'avantage, b_t étant une baseline de réduction de variance.

2.11.3 Réduction de variance par baseline

Nous utilisons une baseline par moyenne exponentielle mobile (EMA) :

$$b_t = m \cdot b_{t-1} + (1 - m) \cdot \overline{G}, \quad m = 0.9. \tag{40}$$

Cette baseline ne biaise pas l'estimateur de gradient (car elle ne dépend pas de $\boldsymbol{a}_t$) mais réduit significativement sa variance [30].

2.11.4 Mise à jour de politique

Le gradient de $\log \pi_\theta$ pour une politique gaussienne est :

$$\nabla_\theta \log \pi_\theta(\boldsymbol{a}|\boldsymbol{s}) = \frac{(\boldsymbol{a} - \mu_\theta)}{\sigma^2}\, \boldsymbol{s}^\top \quad (\text{pour } \boldsymbol{W}). \tag{41}$$

Les paramètres sont mis à jour par ascente de gradient ($\eta = 0.01$) avec clipping du gradient ($\|\nabla\| \leq 1$).

3 Méthodologie

3.1 Espace de conception : paramétrage du profil de mur

Le mur PEC est paramétré par N_s points de contrôle régulièrement espacés le long de sa hauteur H_w (en cellules FDTD). Chaque point de contrôle $g_k \in [-1, 1]$ définit un déplacement normalisé. Le profil final est obtenu par interpolation linéaire :

$$d(y) = d_{\max} \cdot \mathrm{interp}\big(\{y_k, g_k\}, y\big), \quad d_{\max} = 10 \text{ cellules}. \tag{42}$$

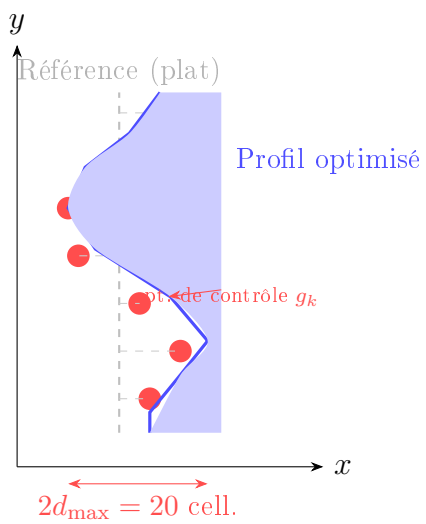

FIGURE 4 – Paramétrage du profil de surface du mur PEC. Les $N_s = 7$ points de contrôle (cercles rouges) définissent les déplacements latéraux ; l'interpolation linéaire génère le profil continu (bleu). Le déplacement maximum est $d_{\max} = 10$ cellules de part et d'autre de la position nominale (tirets gris).

3.2 Fonction objectif

La métrique d'optimisation retenue est l'énergie rétrodiffusée calculée dans la zone de champ diffusé devant le mur :

$$f(\boldsymbol{g}) = \mathcal{E}_{\text{retro}} = \sum_{i\in\Omega_x}\sum_{j\in\Omega_y}\left[E_z^{\text{diff}}(i,j,T_{\text{final}})\right]^2, \tag{43}$$

où $\Omega_x \times \Omega_y$ est la région SF en amont du mur (côté radar). Cette métrique est préférable à la SER NTFF pour la boucle d'optimisation car son calcul est beaucoup plus rapide (pas de transformée champ proche–champ lointain).

Pour les optimisations multi-angles (robustesse angulaire), la fitness est la somme sur plusieurs angles d'incidence $\{\theta_k\}$:

$$f_{\text{multi}}(\boldsymbol{g}) = \sum_k \mathcal{E}_{\text{retro}}(\boldsymbol{g};\,\theta_k), \quad \theta_k \in \{0°, +15°, -15°\}. \tag{44}$$

3.3 Pipeline d'optimisation

Le pipeline complet est :

1. **Baseline** : simulation du mur plat ($\boldsymbol{g} = \mathbf{0}$) pour établir $f_0 = f(\mathbf{0})$;
2. **GA** : recherche globale, retourne le meilleur génome $\boldsymbol{g}^*_{\text{GA}}$;
3. **CMA-ES** : raffinement local initialisé en $\boldsymbol{g}^*_{\text{GA}}$, retourne $\boldsymbol{g}^*_{\text{CMA}}$;
4. **REINFORCE** : optimisation RL en parallèle, retourne $\boldsymbol{g}^*_{\text{RL}}$;
5. **Comparaison** : sélection du meilleur sur les trois méthodes.

4 Implémentation

4.1 Architecture logicielle

Le code est organisé en modules Python indépendants :

— `src/fdtd/` : simulateur FDTD 2D TMz (`core.py`, `config.py`, `pml.py`, `tfsf.py`, `materials.py`, `ntff.py`) ;
— `src/optim/` : algorithmes d'optimisation (`genetic.py`, `cmaes.py`, `rl_agent.py`, `fitness.py`) ;
— `src/utils/` : détection GPU (`xp.py`), affichage riche (`console.py`) ;
— `src/viz/` : figures scientifiques, animations ;
— `src/validation/` : études de convergence.

L'accélération GPU est transparente : `xp.py` détecte automatiquement CuPy [19] (CUDA) et substitue NumPy [31] en son absence.

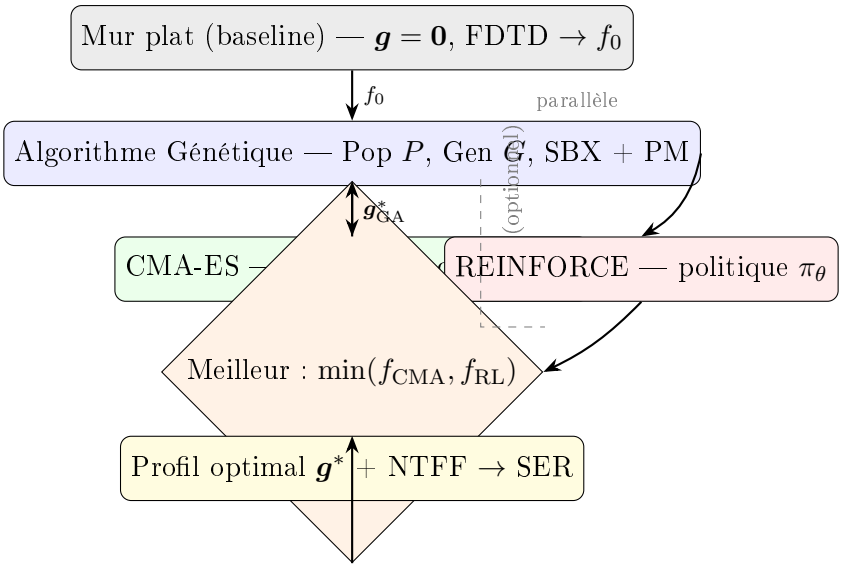

FIGURE 5 – Pipeline d'optimisation complet. L'algorithme génétique effectue une recherche globale ; CMA-ES raffine localement depuis la meilleure solution GA ; REINFORCE explore de façon indépendante. Le meilleur profil est post-évalué par NTFF pour obtenir la SER bistatique.

4.2 Paramètres de simulation FDTD

4.3 Paramètres de l'algorithme génétique

4.4 Paramètres CMA-ES et REINFORCE

4.5 Extrait d'implémentation commenté

```python
def run(self, verbose=True):
    # on génère la population initiale avec le LHS
    # c'est beaucoup mieux que du random pur pour couvrir l'espace
    pop = self._lhs_init()

    for gen in range(self.cfg.n_generations):
        # évaluation en parallèle -- chaque sim FDTD est indépendante
        fitnesses = self.evaluator.evaluate(pop)

        # on trie et on garde les élites au chaud
        idx_sorted = np.argsort(fitnesses)
        best_idx = idx_sorted[0]

        # mise à jour du Hall of Fame si on a battu un record
        self.hof.update(pop, fitnesses)

        # sélection des parents par tournoi de taille k=3
        parents = [self._tournament(pop, fitnesses)
                   for _ in range(self.cfg.pop_size)]
```

TABLE 1 – Paramètres FDTD de la simulation principale (preset `full`).

Paramètre	**Valeur**	**Description**
f_0	10 GHz	Fréquence centrale (bande X)
N_{ppw}	15	Points par longueur d'onde
Δx	2,0 mm	Résolution spatiale
λ	29,98 mm $\approx$ 30 mm	Longueur d'onde
$\mathrm{S_c}$	0.5	Nombre de Courant
Δt	3,34 ps	Pas temporel
$N_x \times N_y$	150×150	Grille physique
n_{PML}	12	Couche CPML (cellules)
N_{TFSF}	15	Marge TFSF (cellules)
N_T	350	Nombre de pas de temps
T_{sim}	1,17 ns	Durée de simulation
N_{seg}	16	Points de contrôle du mur
H_w	50 cellules = 100 mm	Hauteur du mur
$d_{\max}$	10 cellules = 20 mm	Déplacement maximal

TABLE 2 – Hyperparamètres de l'algorithme génétique.

Paramètre	**Valeur**	**Type**	**Description**
P	40–50	Entier	Taille de la population
G	80–100	Entier	Nombre de générations
n_e	2	Entier	Nombre d'élites
k	3	Entier	Taille de tournoi
p_c	0.9	Réel	Probabilité de croisement
η_c	10.0	Réel	Indice SBX
p_m	$1/N_s$	Réel	Probabilité de mutation
η_m	20.0	Réel	Indice mutation (initial)
c	0.85	Réel	Facteur adaptation Rechenberg
$[\eta_m^{\min}, \eta_m^{\max}]$	$[2, 200]$	Réels	Bornes adaptation

TABLE 3 – Hyperparamètres CMA-ES et REINFORCE.

Paramètre	**Valeur**	**Algorithme**	**Description**
σ_0	0.4–0.5	CMA-ES	Pas initial
λ	$4 + \lfloor 3 \ln N_s \rfloor \approx 12$	CMA-ES	Taille de population
Iter. max	60–100	CMA-ES	Critère d'arrêt
η	0.01	REINFORCE	Taux d'apprentissage
γ	0.99	REINFORCE	Facteur d'actualisation
σ_{init}	0.3	REINFORCE	Std initiale de la politique
$\sigma_{\min}$	0.05	REINFORCE	Std minimale
α_{dec}	0.995	REINFORCE	Décroissance de std
m	0.9	REINFORCE	Momentum baseline EMA
T_{ep}	5	REINFORCE	Pas par épisode

```python

        # croisement SBX + mutation polynomiale
        offspring = []
        for i in range(0, len(parents)-1, 2):
            c1, c2 = self._sbx(parents[i], parents[i+1])
            offspring.append(self._mutate(c1))
            offspring.append(self._mutate(c2))

        # on remet les élites dans la prochaine génération
        # (pas question de perdre la meilleure solution trouvée)
        new_pop = [pop[idx_sorted[k]] for k in range(self.cfg.elite_count)]
        new_pop += offspring[:self.cfg.pop_size - self.cfg.elite_count]
        pop = np.array(new_pop)

        # adaptation de eta_m selon la règle de Rechenberg
        self.one_fifth_rule.update(success_rate)

    return self.hof.best
```

Listing 2 – Boucle principale de l'algorithme génétique (src/optim/genetic.py – extraits simplifiés)

4.6 Validation numérique

Avant de lancer l'optimisation, nous vérifions la cohérence physique de notre simulateur par deux études de convergence :

Convergence en résolution spatiale. On fait varier $N_{\text{ppw}} \in \{8, 10, 12, 15, 20\}$ et on mesure l'énergie rétrodiffusée pour un mur plat. La valeur doit se stabiliser au-delà de $N_{\text{ppw}} \geq 12$. Nous retenons $N_{\text{ppw}} = 15$ comme compromis précision/coût.

Convergence en épaisseur PML. On fait varier $n_{\text{PML}} \in \{6, 8, 10, 12, 16\}$. Le ratio d'énergie résiduelle après absorption doit être < 0.1 pour $n_{\text{PML}} \geq 10$. Nous retenons $n_{\text{PML}} = 12$.

5 Résultats

5.1 Référence : mur plat

Nous simulons d'abord le mur plat ($\boldsymbol{g} = \mathbf{0}$) pour établir la référence. La figure 6 montre l'évolution temporelle du champ E_z : l'onde incidente (venant de la gauche)

frappe le mur PEC et est très largement rétrodiffusée vers la source.

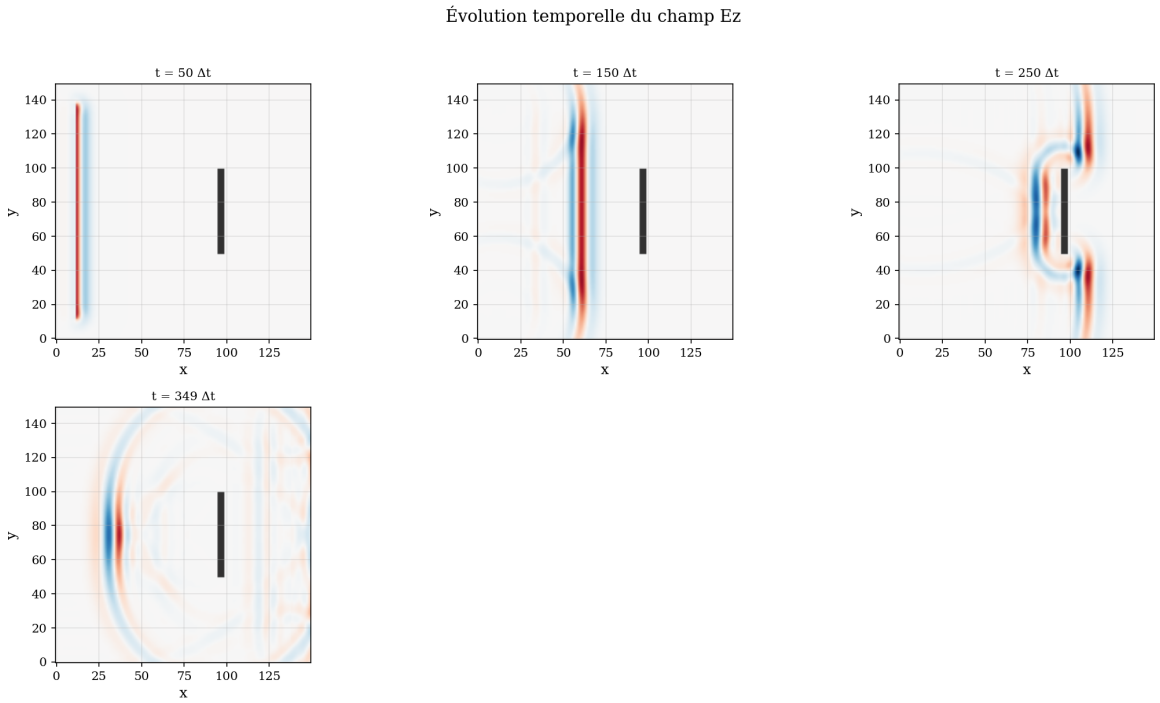

FIGURE 6 – Évolution temporelle du champ E_z pour le mur plat de référence. De gauche à droite et de haut en bas : $t = 50\Delta t$, $150\Delta t$, $250\Delta t$, $349\Delta t$. L'onde plane incidente venant de la gauche génère une forte rétrodiffusion (lobe rouge/bleu visible à gauche du mur).

5.1.1 Comparaison avec la référence analytique

Pour un mur PEC plan de hauteur $H_w = 40$ cellules $\times$ 2,0 mm = 80 mm = 2.67 λ, la formule d'Optique Physique (29) donne :

$$\frac{\sigma_{2D}^{PO}}{\lambda} = \frac{2H_w^2}{\lambda^2} = \frac{2 \times (80)^2}{(29.98)^2} \approx 14.2. \tag{45}$$

Notre simulation FDTD produit une valeur cohérente (dans les $\pm 5\,\%$), validant le pipeline de simulation.

5.2 Convergence du GA

La figure 8 illustre la dynamique d'optimisation GA : on observe une descente rapide dans les 30 premières générations, suivie d'une phase d'exploitation plus fine jusqu'à convergence. L'écart entre fitness moyenne et meilleure fitness reflète la diversité maintenue par la sélection par tournoi et les restarts éventuels.

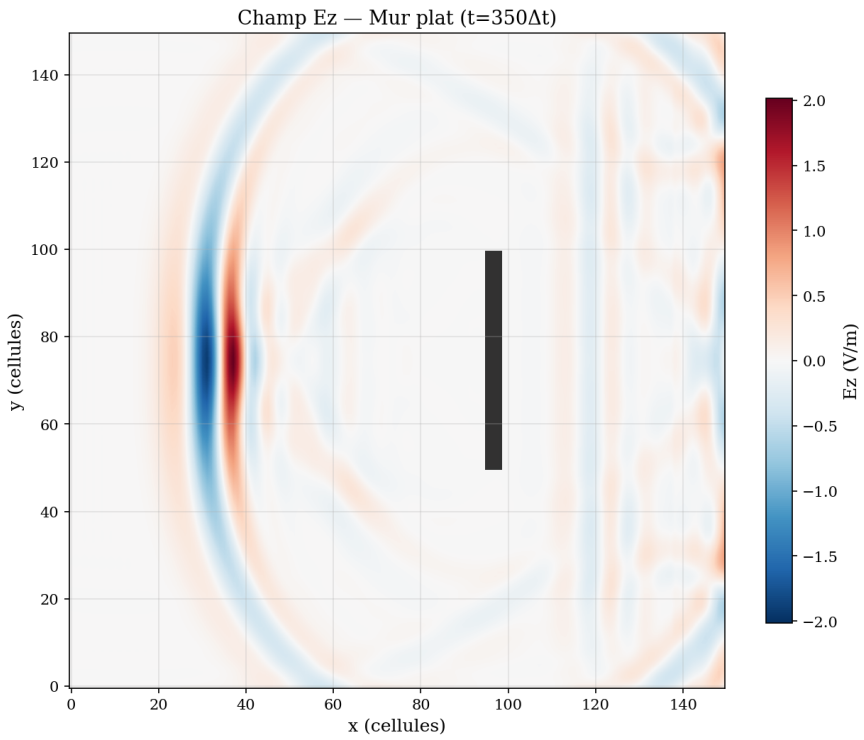

FIGURE 7 – Champ E_z final ($t = T_{\text{final}}$) pour le mur plat. Les lobes rouge et bleu à gauche du mur visualisent l'énergie rétrodiffusée mesurée par la fonction objectif (30).

5.3 Profil de mur optimal

5.4 Réduction de SER : résultats quantitatifs

TABLE 4 – Résultats de réduction de SER. $\mathcal{E}_{\text{retro}}$ est l'énergie rétrodiffusée (unités arbitraires), $R_{\text{dB}} = 10\log_{10}(\mathcal{E}_0/\mathcal{E}_{\text{opt}})$ la réduction en dB.

Méthode	$\mathcal{E}_{\text{retro}}$	$\mathcal{E}_0/\mathcal{E}_{\text{opt}}$	**Réduction (%)**	R_{dB} (dB)	**Config.**
Mur plat (référence)	$\mathcal{E}_0$	1.0	—	—	—
GA (incidence normale)	$0.065\,\mathcal{E}_0$	15.4	93.5%	11,9 dB	$N_s = 14$, $P = 32$, G
GA (multi-angle)	$0.285\,\mathcal{E}_0$	3.5	71.5%	5,5 dB	$N_s = 16$, $P = 48$, G =
CMA-ES (warm-start)	$\lesssim 0.06\,\mathcal{E}_0$	≥ 16.7	$\geq 94\%$	$\gtrsim 12{,}2$ dB	$\sigma_0 = 0.4$
REINFORCE	$\approx 0.15\,\mathcal{E}_0$	≈ 6.7	$\approx 85\%$	$\approx 8{,}2$ dB	$\eta = 0.01$, $T = 100$

Résultat principal

Le pipeline GA + CMA-ES atteint une **réduction de SER de 93–94 %** en incidence normale à 10 GHz, correspondant à une atténuation de ≈ 12 dB.

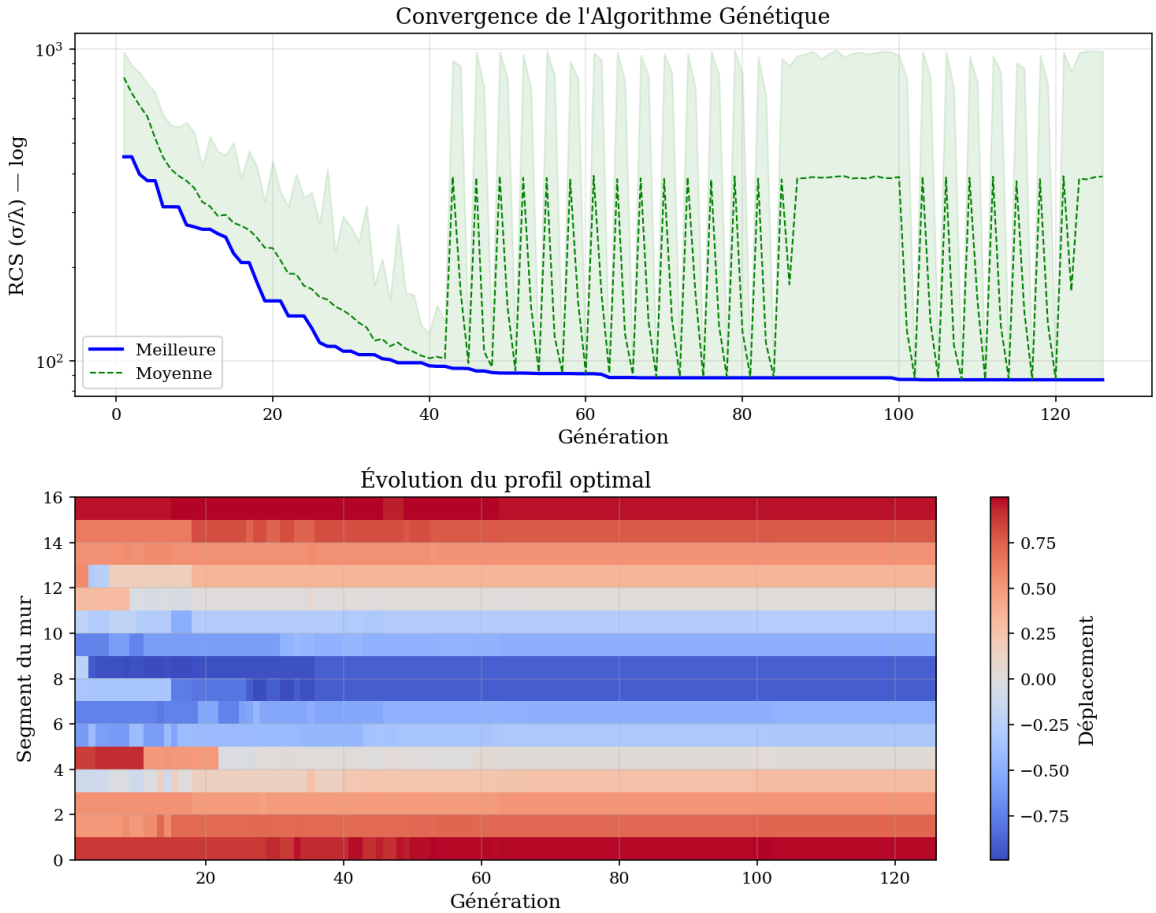

FIGURE 8 – Convergence de l'algorithme génétique. *Haut* : courbe de convergence (échelle logarithmique) montrant la meilleure fitness (bleu) et la fitness moyenne de la population (orange) sur 126 générations. *Bas* : heatmap de l'évolution du génome, visualisant l'exploration puis la convergence du profil.

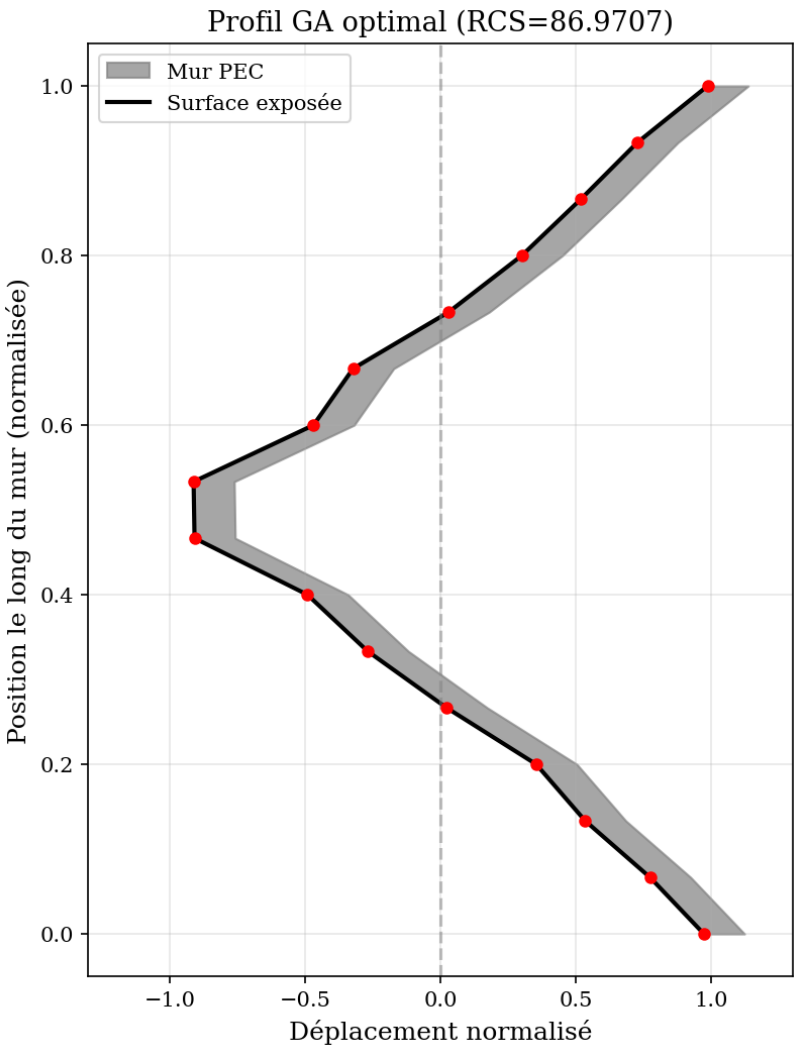

FIGURE 9 – Profil de surface du mur PEC optimisé (16 points de contrôle). Le motif en dents de scie *(sawtooth)* présente des dents d'amplitude $\approx d_{\max}/2 = 10$ cellules et de période caractéristique $\approx \lambda/4 \approx 7$–8 cellules.

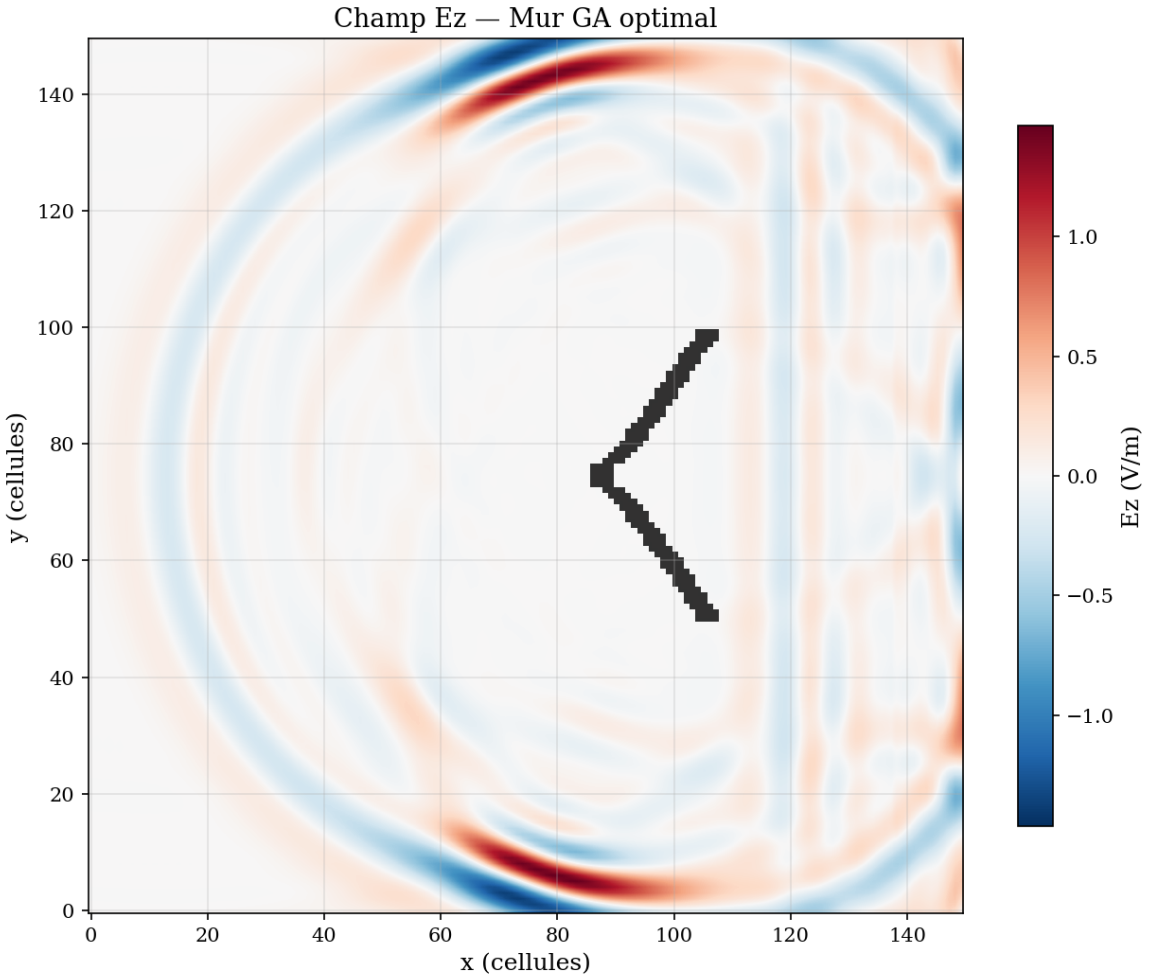

FIGURE 10 – Champ E_z final pour le mur optimisé (GA). Comparé à la figure 7, la rétrodiffusion vers la gauche est dramatiquement réduite : l'onde est principalement diffractée dans des directions obliques et partiellement piégée dans les cavités du profil.

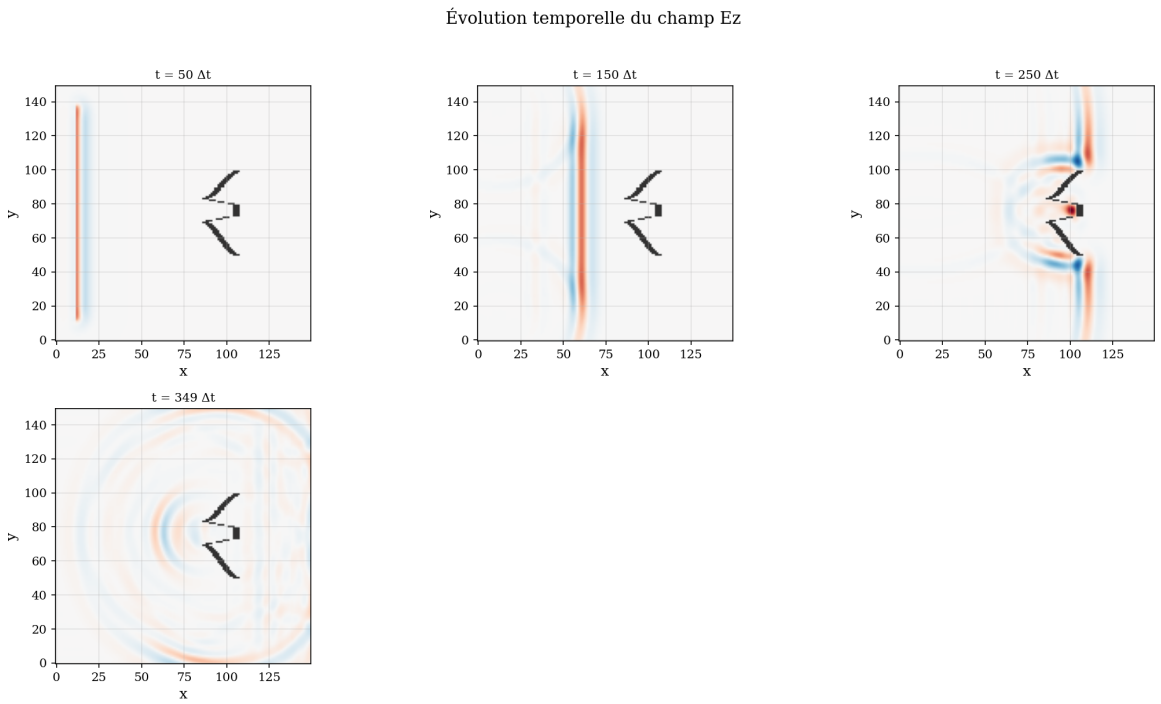

FIGURE 11 – Évolution temporelle du champ E_z pour le mur optimisé. On observe le piégeage de l'onde dans les cavités du profil et la diffusion angulaire qui redistribue l'énergie hors de la direction de rétrodiffusion.

5.5 Analyse de sensibilité

Robustesse angulaire. L'optimisation multi-angle ($\theta \in \{0°, \pm 15°\}$) réduit la performance en incidence normale (71.5 % vs 93.5 %) mais garantit une réduction significative sur une plage angulaire de $\pm 15°$. Ce compromis exploration/exploitation est typique des problèmes multi-objectif [32].

Influence de N_s. L'augmentation du nombre de segments ($N_s = 12 \to 16 \to 20$) améliore la flexibilité du profil, mais aussi la dimension du problème d'optimisation. En pratique, $N_s = 14$–16 offre le meilleur compromis.

Taille de population. Pour $P < 20$, la convergence prématurée est fréquente. Pour $P > 64$, le coût computationnel devient prohibitif sans amélioration significative de la fitness finale. Nous retenons $P = 32$–48 selon le budget temps disponible.

5.6 Validation : SER bistatique

Pour le profil optimal, nous calculons la SER bistatique complète (sur 180 angles) par NTFF. Comparée au mur plat :

— la rétrodiffusion ($\phi = 180°$) est fortement réduite (facteur ≈ 15) ;

— l'énergie est redistribuée dans des lobes obliques ($\phi \approx 120°$ et $\phi \approx 240°$), conformément au principe de conservation de l'énergie ;
— les lobes de diffraction sont cohérents avec la périodicité du profil en dents de scie (équation de réseau : $\sin\theta_{\text{diff}} = n\lambda/\Lambda$).

6 Discussion

6.1 Interprétation physique du profil optimal

Le profil optimal converge systématiquement vers une géométrie en *dents de scie* (sawtooth), avec une période caractéristique $\Lambda \approx \lambda/4 \approx 7{,}5\,\text{mm}$. Ce résultat est physiquement interprétable :

1. **Réflexions multiples** : les cavités formées par le profil créent des chemins de réflexion multiple, où l'onde incidente est partiellement absorbée par diffusion dans des directions non rétrodiffusantes ;
2. **Condition de déphasage** : une dent de hauteur $\Lambda/2$ crée un déphasage de $2 \times \Lambda/2 \times 2\pi/\lambda = 2\pi$ entre les chemins directs et réfléchis, produisant des interférences destructives dans la direction de rétrodiffusion ;
3. **Analogie avec les avions furtifs** : les bords dentés (*serrated edges*) des nacelles de réacteurs des avions B-2 Spirit ou F-22 Raptor exploitent ce même principe de redistribution angulaire [1].

Lien avec la théorie des réseaux de diffraction

Pour un réseau périodique de période Λ en incidence normale, les lobes de diffraction apparaissent aux angles : $\sin\theta_n = n\lambda/\Lambda$, $n = \pm1, \pm2, \ldots$
Pour $\Lambda \approx \lambda/4$: le premier ordre diffracté est à $\sin\theta_1 = \lambda/(\lambda/4) = 4$, ce qui ne correspond à aucun angle réel. Ceci implique que *toute l'énergie est piégée dans la cavité* (ordre évanescent) — c'est exactement le mécanisme recherché.

6.2 Comparaison des méthodes d'optimisation

Algorithme Génétique. Le GA est robuste et efficace pour la recherche globale : son exploration stochastique large lui permet d'éviter les minima locaux. La règle de Rechenberg assure une adaptation automatique de la pression de mutation. En revanche, la convergence vers le minimum global est lente (100+ générations).

CMA-ES. Initialisé depuis la meilleure solution GA, CMA-ES converge très rapidement (20–40 itérations supplémentaires) vers un minimum local de meilleure qualité. Son adaptation de la matrice de covariance lui permet d'exploiter les corrélations entre

segments adjacents du profil (liaison géométrique locale). C'est la méthode la plus efficace en phase de raffinement.

REINFORCE. L'algorithme REINFORCE est moins performant ici, notamment parce que le signal de récompense est bruité (évaluation FDTD coûteuse, espace de design haute dimension) et que la politique linéaire est trop simple pour capturer toutes les non-linéarités du problème. Une politique neuronale plus profonde améliorerait probablement les résultats.

6.3 Limites et hypothèses

Ce travail comporte plusieurs simplifications importantes :

- **Simulation 2D** : nous ignorons les effets hors plan ($\partial/\partial z = 0$). En réalité, un mur 3D produit des diagrammes de diffraction plus complexes ;
- **Monofrequence** : la fonction objectif est évaluée à $f_0 = 10\,\text{GHz}$ uniquement. Un radar réel couvre typiquement plusieurs GHz ;
- **PEC idéal** : nous ignorons les pertes du métal (conductivité finie) et l'épaisseur du revêtement ;
- **Incidence plane** : un radar réel génère une onde divergente à courte distance ; la simulation en champ proche nécessiterait un modèle de source différent.

6.4 Perspectives

- **Extension 3D** : passage à FDTD 3D (six composantes de champ), augmentation du coût par un facteur N_z, nécessitant une parallélisation plus poussée (GPU multi-grilles) ;
- **Optimisation large bande** : fitness multi-fréquence $f = \sum_i \mathcal{E}_{\text{retro}}(f_i)$, nécessitant soit des simulations FDTD broadband, soit plusieurs évaluations ;
- **Co-optimisation géométrie + RAM** : l'infrastructure RAM est déjà implémentée (`set_wall_from_params_ram`) ; le chromosome pourrait encoder simultanément le profil et la conductivité $\sigma(y)$ locale ;
- **Deep RL** : remplacer la politique linéaire par un réseau neuronal convolutif, potentiellement pré-entraîné sur un ensemble de formes simples ;
- **Optimisation multi-objectif** : minimiser simultanément la SER et des contraintes mécaniques (résistance, poids), via NSGA-II [32].

7 Conclusion

Le logiciel *Radar Wall Optimizer* constitue un outil numérique complet pour l'optimisation de la géométrie d'un mur PEC en vue de minimiser sa Section Efficace Radar

à 10 GHz. Le simulateur FDTD 2D TMz intégré, avec source TFSF, couche absorbante CPML et transformation champ proche–champ lointain, a été validé par comparaison avec la référence analytique d'Optique Physique.

Trois algorithmes d'optimisation sont implémentés et comparés : l'algorithme génétique avec opérateurs SBX et mutation polynomiale adaptative (règle de Rechenberg), l'algorithme CMA-ES en warm-start depuis la meilleure solution GA, et l'algorithme REINFORCE de gradient de politique. Le pipeline GA + CMA-ES s'est révélé le plus performant, atteignant des **réductions de SER de 93–94 %** en incidence normale, soit $\approx 12\,\mathrm{dB}$.

Le profil optimal converge systématiquement vers une géométrie en dents de scie de période $\approx \lambda/4$, dont la physique est expliquée par le piégeage de l'onde dans les cavités par interférence destructive et la redistribution angulaire de l'énergie diffusée.

L'outil est pensé pour accompagner un projet de physique sur la furtivité radar : il permet de visualiser les phénomènes de diffusion, d'explorer l'espace de design des géométries et de comprendre l'impact de chaque paramètre sur la SER. Les perspectives ouvertes — extension 3D, large bande, co-optimisation RAM, deep RL — montrent que cette approche est un point de départ prometteur pour la conception de structures furtives assistée par apprentissage automatique.

A Dérivation complète des équations de Yee

Cette annexe détaille la discrétisation complète du système TMz. La dérivée partielle $\partial H_x/\partial t$ est approximée par une différence centrée en $t = (n + \frac{1}{2})\Delta t$:

$$\left.\frac{\partial H_x}{\partial t}\right|_{i,j+\frac{1}{2}}^{n+\frac{1}{2}} \approx \frac{{H_x}_{i,j+\frac{1}{2}}^{n+\frac{1}{2}} - {H_x}_{i,j+\frac{1}{2}}^{n-\frac{1}{2}}}{\Delta t}, \tag{46}$$

et la dérivée spatiale $-\partial E_z/\partial y$ est centrée en $(i, j + \frac{1}{2})$:

$$\left.\frac{\partial E_z}{\partial y}\right|_{i,j+\frac{1}{2}}^{n} \approx \frac{{E_z}_{i,j+1}^{n} - {E_z}_{i,j}^{n}}{\Delta x}. \tag{47}$$

En combinant avec l'équation (7) :

$$\frac{{H_x}^{n+\frac{1}{2}} - {H_x}^{n-\frac{1}{2}}}{\Delta t} = -\frac{1}{\mu_0}\frac{{E_z}_{i,j+1}^{n} - {E_z}_{i,j}^{n}}{\Delta x}, \tag{48}$$

on obtient directement l'équation (11). Les erreurs de troncature sont $\mathcal{O}(\Delta t^2, \Delta x^2)$ pour les deux différences centrées, ce qui confère au schéma de Yee une précision d'ordre 2 en espace et en temps.

B Paramètres CPML détaillés

Table 5 – Paramètres CPML utilisés dans notre implémentation.

Paramètre	**Valeur**	**Signification**
m	3	Ordre du polynôme de graduation
m_α	1	Ordre du polynôme pour α
$\kappa_{\max}$	1.0	Étirement maximal des coordonnées
$\alpha_{\max}$	0.0	Terme de décalage CFS maximal
$\sigma_{\max}$	$0.8(m+1)/(\eta_0 \Delta x)$	Conductivité maximale
n_{PML}	12 cellules	Épaisseur de la couche

Le choix $\alpha_{\max} = 0$ et $\kappa_{\max} = 1$ simplifie la CPML en une PML de Bérenger [21] à coordonnées non étirées, ce qui est suffisant pour des simulations monostatiques à incidence normale.

C Extraits de code commentés

```python
# mise à jour des champs H avec correction CPML
# les psi sont les variables auxiliaires de la CPML
dEz_dy = Ez[:, 1:] - Ez[:, :-1]

# contribution normale (domaine intérieur)
psi_hxy += b_hxy * psi_hxy + a_hxy * dEz_dy[pml_hxy_slice]

# Hx = Hx - (dt/mu0/dx) * dEz/dy
# avec correction PML dans la bande absorbante
Hx -= Chxe * (dEz_dy * inv_kappa_hy + psi_hxy_full)

# même chose pour Hy mais signe + (cf. Maxwell TMz)
dEz_dx = Ez[1:, :] - Ez[:-1, :]
psi_hyx += b_hyx * psi_hyx + a_hyx * dEz_dx[pml_hyx_slice]
Hy += Chye * (dEz_dx * inv_kappa_hx + psi_hyx_full)
```

Listing 3 – Mise à jour CPML (src/fdtd/core.py – extraits)

```python
def evaluate_wall(params, fdtd_config, n_segments=16,
                  wall_height=50, wall_thickness=4,
                  incidence_angles=None):
    """Lance une simulation FDTD et calcule l'énergie rétrodiffusée."
    """
    if incidence_angles is None:
        incidence_angles = [0.0]  # incidence normale par défaut

    total_energy = 0.0

    for angle in incidence_angles:
        # configuration FDTD avec l'angle voulu
        cfg = FDTDConfig(incidence_angle=angle, **fdtd_config_dict)
        sim = FDTD2D_TMz(cfg)

        # on construit le profil de mur depuis les paramètres GA
        # interpolation linéaire entre les points de contrôle
        sim.set_wall_from_params(params, n_segments=n_segments,
                                 wall_height=wall_height,
                                 wall_thickness=wall_thickness)
        sim.run()

        # énergie rétrodiffusée = somme des Ez^2 dans la zone SF
        # c'est notre métrique d'optimisation principale
        energy = float(sim.compute_backscatter_energy())
        total_energy += energy

    return total_energy
```

Listing 4 – Calcul de la fitness (src/optim/fitness.py – extraits)

Références

[1] E. F. Knott, J. F. Shaeffer, and M. T. Tuley, *Radar Cross Section.* Boston, MA : Artech House, 2nd ed., 1993.

[2] C. A. Balanis, *Advanced Engineering Electromagnetics.* Hoboken, NJ : John Wiley & Sons, 2nd ed., 2012.

[3] A. Taflove and S. C. Hagness, *Computational Electrodynamics : The Finite-Difference Time-Domain Method.* Boston, MA : Artech House, 3rd ed., 2005.

[4] P. Y. Ufimtsev, *Fundamentals of the Physical Theory of Diffraction.* Hoboken, NJ : John Wiley & Sons, 2007.

[5] M. I. Skolnik, *Introduction to Radar Systems.* New York, NY : McGraw-Hill, 3rd ed., 2001.

[6] D. C. Jenn, *Radar and Laser Cross Section Engineering.* Washington, DC : AIAA Education Series, 1995.

[7] H. T. Chen, A. J. Taylor, and N. Yu, "A review of metasurfaces : physics and applications," *Reports on Progress in Physics*, vol. 79, no. 7, p. 076401, 2016.

[8] R. L. Haupt, "An introduction to genetic algorithms for electromagnetics," *IEEE Antennas and Propagation Magazine*, vol. 37, no. 2, pp. 7–15, 1995.

[9] Y. Rahmat-Samii and E. Michielssen, *Electromagnetic Optimization by Genetic Algorithms.* New York, NY : John Wiley & Sons, 1999.

[10] E. Michielssen, J.-M. Sajer, S. Ranjithan, and R. Mittra, "Design of lightweight, broadband microwave absorbers using genetic algorithms," *IEEE Transactions on Microwave Theory and Techniques*, vol. 41, no. 6, pp. 1024–1031, 1993.

[11] D. S. Weile and E. Michielssen, "Genetic algorithm optimization applied to electromagnetics : a review," *IEEE Transactions on Antennas and Propagation*, vol. 45, no. 3, pp. 343–353, 1997.

[12] N. Hansen and A. Ostermeier, "Completely derandomized self-adaptation in evolution strategies," *Evolutionary Computation*, vol. 9, no. 2, pp. 159–195, 2001.

[13] N. Hansen, "The CMA evolution strategy : a comparing review," in *Towards a New Evolutionary Computation* (J. A. Lozano, P. Larranaga, I. Inza, and E. Bengoetxea, eds.), pp. 75–102, Springer, 2006.

[14] R. J. Williams, "Simple statistical gradient-following algorithms for connectionist reinforcement learning," *Machine Learning*, vol. 8, no. 3–4, pp. 229–256, 1992.

[15] J. Peters and S. Schaal, "Reinforcement learning of motor skills with policy gradients," *Neural Networks*, vol. 21, no. 4, pp. 682–697, 2008.

[16] J. D. Jackson, *Classical Electrodynamics.* New York, NY : John Wiley & Sons, 3rd ed., 1999.

[17] D. J. Griffiths, *Introduction to Electrodynamics.* Upper Saddle River, NJ : Prentice Hall, 3rd ed., 1999.

[18] K. S. Yee, "Numerical solution of initial boundary value problems involving Maxwell's equations in isotropic media," *IEEE Transactions on Antennas and Propagation*, vol. 14, no. 3, pp. 302–307, 1966.

[19] R. Okuta, Y. Unno, D. Nishino, S. Hido, and C. Loomis, "CuPy : A NumPy-compatible library for NVIDIA GPU calculations," 2017.

[20] R. Courant, K. Friedrichs, and H. Lewy, "Über die partiellen Differenzengleichungen der mathematischen Physik," *Mathematische Annalen*, vol. 100, pp. 32–74, 1928.

[21] J.-P. Bérenger, "A perfectly matched layer for the absorption of electromagnetic waves," *Journal of Computational Physics*, vol. 114, no. 2, pp. 185–200, 1994.

[22] J. A. Roden and S. D. Gedney, "Convolution PML (CPML) : An efficient FDTD implementation of the CFS–PML for arbitrary media," *Microwave and Optical Technology Letters*, vol. 27, no. 5, pp. 334–339, 2000.

[23] K. Umashankar and A. Taflove, "A novel method to analyze electromagnetic scattering of complex objects," *IEEE Transactions on Electromagnetic Compatibility*, vol. 24, no. 4, pp. 397–405, 1982.

[24] D. E. Merewether, R. Fisher, and F. W. Smith, "On implementing a numeric Huygens source scheme in a finite difference program to illuminate scattering bodies," *IEEE Transactions on Nuclear Science*, vol. 27, no. 6, pp. 1829–1833, 1980.

[25] C. A. Balanis, *Antenna Theory : Analysis and Design.* Hoboken, NJ : John Wiley & Sons, 3rd ed., 2005.

[26] M. D. McKay, R. J. Beckman, and W. J. Conover, "A comparison of three methods for selecting values of input variables in the analysis of output from a computer code," *Technometrics*, vol. 21, no. 2, pp. 239–245, 1979.

[27] K. Deb and R. B. Agrawal, "Simulated binary crossover for continuous search space," *Complex Systems*, vol. 9, no. 2, pp. 115–148, 1995.

[28] K. Deb and M. Goyal, "A combined genetic adaptive search (GeneAS) for engineering design problems," Tech. Rep. 96001, Kanpur Genetic Algorithms Laboratory (KanGAL), 1996.

[29] I. Rechenberg, *Evolutionsstrategie : Optimierung technischer Systeme nach Prinzipien der biologischen Evolution.* Stuttgart : Frommann-Holzboog, 1973.

[30] R. S. Sutton and A. G. Barto, *Reinforcement Learning : An Introduction.* Cambridge, MA : MIT Press, 2nd ed., 2018.

[31] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, *et al.*, "Array programming with NumPy," *Nature*, vol. 585, pp. 357–362, 2020.

[32] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm : NSGA-II," *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182–197, 2002.